

Classificador Naive Bayes em Larga Escala (500k Registros)

Arquitetura de Alta Performance em Rust + Apache Polars adaptada à Edafologia de Mato Grosso

1. Visão Geral e Arquitetura do Projeto

Este projeto substitui os bancos de dados relacionais convencionais por uma infraestrutura analítica de alta performance escrita em **Rust** e apoiada pelo **Apache Polars**. O objetivo é executar a matemática completa do classificador probabilístico **Naive Bayes** sobre um conjunto massivo de **500.000 talhões agrícolas em Mato Grosso** de forma vetorizada, multithread e com segurança de memória.

Rótulo Alvo (Decisão Binária):

- `quebra_safra = 'sim'` (Produtividade < 70% da média histórica; acionamento de sinistro)
- `quebra_safra = 'nao'` (Safr regular dentro da meta econômica regional)

2. Estrutura Completa de Pastas e Arquivos do Repositório

```
naive_bayes_agro_mt/
├── Cargo.toml                # Manifesto e dependências de compilação em Rust
├── README.md                 # Instruções de reprodução, build e execução
├── docs/
│   ├── modelagem/
│   │   ├── definicao_problema.md    # Rótulo alvo, objetivos e justificativas regionais
│   │   └── dicionario_features.md  # As 7 variáveis calibradas com o ZARC/MT
│   ├── prompts/
│   │   └── historico_dialogo_ia.md  # Registro integral do diálogo e decisões com a IA
│   └── relatorio/
│       ├── analise_casos_teste.md   # Interpretação dos 5 cenários avaliados
│       └── reflexao_critica.md      # Análise de limitações perante a banca agrônômica
├── scripts/
│   └── gerar_dataset_500k.py        # Script gerador da base sintética com regras de MT
├── dataset/
│   ├── treinamento_mt_500k.csv      # Base histórica com 500.000 registros
│   └── casos_teste.csv              # Os 5 perfis de talhões para validação
└── src/
    ├── main.rs                     # Pipeline principal: carga, multithread, testes e métricas
    ├── bayes.rs                    # Matemática artesanal do Naive Bayes (Laplace, Log-odds)
    └── tipos.rs                     # Estruturas de dados (structs) e tipos auxiliares
```

3. Modelagem Edafológica e Agronômica (Features Calibradas ZARC/MT)

Feature	Categorias Discretizadas	Fundamentação Técnica e Impacto Regional em MT
classe_pedologica	latossolo_argiloso , plintossolo_cerrado , neossolo_arenoso	Latossolos profundos do Médio-Norte retêm água por mais tempo; Neossolos quartzarênicos (< 15% argila) do Araguaia e Parecis colapsam em poucos dias de sol intenso.
deficit_hidrico_estadio	sem_deficit_reprodutivo , moderado_vegetativo , severo_fase_r1_r5	O estresse hídrico no enchimento de

Feature	Categorias Discretizadas	Fundamentação Técnica e Impacto Regional em MT
		grãos (R1-R5) provoca chochamento e abortamento irreversível; na fase vegetativa a cultura apresenta maior resiliência.
regime_chuva	deficitario , regular_ideal , excessivo_colheita	Déficit quebra o rendimento das vagens; chuvas excessivas na fase de colheita causam o apodrecimento dos grãos no pé (grãos ardidos comerciais).
janela_zarc	ideal_outubro , ajustada_novembro , tardia_dezembro	Conforme o Zoneamento de Risco Climático da Embrapa, semeaduras em dezembro inviabilizam o milho 2ª safra e elevam a pressão de esporos de ferrugem.
sistema_cultivo	sequeiro_convencional , sequeiro_plantio_direto , irrigado_pivo	Plantio direto consolidado com palhada densa preserva a umidade residual do solo; sistemas sob pivô central anulam a dependência imediata do clima.
pressao_fitossanitaria	baixa_preventiva , moderada_monitorada , critica_escape	Controle fitossanitário integrado para ferrugem asiática (<i>Phakopsora pachyrhizi</i>), percevejos-marrom e nematóides endêmicos de solos arenosos.
microrregiao_altitude	chapadao_alta (>600m), depressao_cuiabana (<300m), transicao_media	Chapadões (Diamantino, Campo Novo) possuem noites mais amenas; baixadas sofrem com calor constante e alta

Feature	Categorias Discretizadas	Fundamentação Técnica e Impacto Regional em MT
		evapotranspiração potencial.

4. Formulação Matemática Implementada no Rust

O motor em Rust executa a inferência probabilística sem caixas-pretas ou bibliotecas de ML prontas, utilizando quatro etapas essenciais:

1. **Probabilidade a Priori Multithread:** Contagem paralela das classes na base histórica dividida pelo total de registros:

$$P(C) = Total(C) / N \implies \ln(P(C)) = \ln(P(C))$$

2. **Verossimilhança com Suavização Dinâmica de Laplace:**

$$P(x_i | C) = [Contagem(x_i \text{ em } C) + 1.0] / [Total \text{ da classe } C + |V_i|]$$

Onde $|V_i|$ é o número dinâmico de categorias distintas da feature observada, evitando divisão por zero e anulação de scores em perfis não vistos.

3. **Adição em Escala Logarítmica (Anti-Underflow):**

$$Score(C) = \ln(P(C)) + \sum_{i=1}^7 \ln(P(x_i | C))$$

4. **Normalização Robusta (Softmax Bayesiano):**

$$P(sim) = \frac{e^{Score(sim) - max}}{e^{Score(sim) - max} + e^{Score(nao) - max}} \times 100$$

A subtração do termo $max(Score(sim), Score(nao))$ elimina riscos de overflow numérico de ponto flutuante.

5. Plano dos 5 Casos de Teste para Validação

- Caso 1 (Baixo Risco - Chapadão Parecis):** Latossolo argiloso, sem déficit em fase crítica, chuva regular, janela outubro, pivô central → **Probabilidade de Quebra esperada < 5%**.
- Caso 2 (Alto Risco Extremo):** Neossolo arenoso, seca severa em R1-R5, chuva deficitária, plantio em dezembro, sequeiro convencional → **Probabilidade de Quebra esperada > 90%**.
- Caso 3 (Dilema Edáfico):** Neossolo arenoso sob pivô central com manejo de irrigação pleno (analisa se a tecnologia compensa a fragilidade do solo areno-quartzarênico).
- Caso 4 (Resiliência da Argila):** Latossolo argiloso exposto a veranico severo e chuva deficitária (mede o poder de amortecimento da microporosidade do solo argiloso).
- Caso 5 (Teste de Laplace):** Talhão com `classe_pedologica = 'gleissolo_desconhecido'` (comprova na prática que o código não quebra com variáveis não registradas no treino).

6. Reflexão Crítica perante a Banca de Avaliação

Vantagens Computacionais: O binário em Rust com Polars executa agrupamentos em 500.000 registros e classifica os talhões em menos de 0,5 segundo, servindo como uma ferramenta ultrarrápida de triagem para cooperativas e seguradoras agrícolas.

Limitação Agronômica Essencial: O algoritmo assume *independência condicional* entre as variáveis. No cerrado mato-grossense, essa hipótese é ecologicamente falsa: um solo arenoso multiplica catastróficamente o impacto da seca durante o enchimento de grãos, pois não possui reserva hídrica. O modelo apenas soma os pesos isoladamente, devendo ser interpretado como um *baseline probabilístico* de crédito, e não como um simulador ecofisiológico de plantas.