

Agronegócio 4.0: Classificação de Risco de Quebra de Safra em MT

Guia Completo da Modelagem ao Código SQL com Edaphologia Típica de Mato Grosso

1. Contexto e Objetivo Geral

O projeto constrói um classificador inteligente probabilístico para prever se um talhão agrícola cultivado em **Mato Grosso** (focado no binômio soja/milho safrinha) terá **quebra severa de safra** (produtividade abaixo de 70% do potencial histórico) ou **safra regular**.

O diferencial exigido pelo professor é a **implementação do Naive Bayes puro em consultas SQL** (usando WITH / CTEs, LN() e EXP()), sem uso de bibliotecas de Machine Learning prontas.

Rótulo Alvo (Variável Dependente Binária):

- `quebra_safra = 'sim'` (Produtividade em colapso / acionamento de seguro rural)
- `quebra_safra = 'nao'` (Produtividade normal ou acima da meta regional)

2. Solos Reais de Mato Grosso: A Grande Mudança da Modelagem

Para refletir a realidade agronômica mato-grossense, substituímos a divisão genérica por classes taxonômicas e texturais características de MT:

- **latossolo_argiloso (Latossolo Vermelho / Vermelho-Amarelo Argiloso):** Típico do Médio-Norte (Sorriso, Sinop, Lucas do Rio Verde, Campo Novo do Parecis). Apresenta excelente retenção hídrica, alta profundidade e suporte superior a períodos de veranico.
- **neossolo_quartzarênico (Arenoso < 15% argila):** Frequente em faixas do Araguaia, Vale do Guaporé e bolsões do Parecis. Possui baixíssima retenção de água e nutrientes, secando criticamente com poucos dias de sol intenso.
- **plintossolo_cerrado (Solo Misto / Concrecionário com restrição):** Comum em áreas de transição e baixadas no estado, suscetível a encharcamento temporário na chuva intensa e rápido ressecamento superficial no estio.

3. Tabela Completa de Features Discretizadas (Etapa 1)

Feature	Categorias Discretizadas	Impacto Agronômico Regional em MT
tipo_solo_mt	latossolo_argiloso, plintossolo_cerrado, neossolo_arenoso	Capacidade de retenção hídrica do talhão; latossolos aguentam estresse hídrico muito melhor que neossolos.
veranico_dias	curto_ate_7d, medio_8_a_14d, severo_mais_14d	Períodos sem chuva entre janeiro e março coincidem com o enchimento de grãos da soja ou germinação do milho 2ª safra.
regime_chuva	deficitario, regular_ideal, excessivo_colheita	Déficit quebra a produtividade; excesso de chuva na colheita

Feature	Categorias Discretizadas	Impacto Agrônômico Regional em MT
		apodrece grãos no pé (grãos ardidos).
janela_plantio	ideal_outubro, ajustada_novembro, tardia_dezembro	Plantio em dezembro empurra a safrinha para abril/maio, época de encerramento das chuvas em MT.
sistema_cultivo	sequeiro_convencional, sequeiro_plantio_direto, irrigado_pivo	Plantio direto consolidado (palhada densa) protege a umidade do solo; pivô zera déficit hídrico.
pressao_fitossanitaria	baixa, moderada_monitorada, critica_surto	Incidência de ferrugem asiática, percevejo-marrom ou nematóides (este último devastador em neossolos).
altitude_microrregiao	chapadão_alta (>600m), depressao_cuiabana (<300m), transicao_media	Chapadões (Diamantino, Sapezal) têm temperaturas noturnas mais amenas; baixadas sofrem com calor escaldante.

4. Como o Algoritmo Opera em SQL (Etapas 2 e 3)

O classificador é implementado inteiramente através de Expressões de Tabela Comuns (CTEs - WITH):

- Treinamento (100+ registros históricos):** A base armazena o histórico de safras passadas de talhões de MT.
- Cálculo do Prior:** Calcula a proporção histórica de quebra ($P(Sim)$) e não quebra ($P(Nao)$), convertendo em $\ln(P(C))$.
- Verossimilhanças com Laplace:**

$$P(x_i | C) = [Contagem(x_i \text{ em } C) + 1] / [Total \text{ em } C + |V_i|]$$

Onde $|V_i|$ é o total de categorias possíveis daquela feature (ex: 3 para solo). A adição do +1 impede multiplicação por zero para combinações raras.

- Soma Logarítmica e Normalização:** Para cada talhão de teste, soma-se $\ln(Prior) + \sum \ln(Verossimilhanças)$. Em seguida, aplica-se a função exponencial e a razão sobre a soma para retornar o percentual de 0 a 100%.

5. Plano dos 5 Casos de Teste (Etapa 4)

- Teste 1 (Baixo Risco - Chapadão Parecís):** latossolo_argiloso, irrigado_pivo, ideal_outubro, curto_ate_7d → Quebra esperada < 5%.
- Teste 2 (Alto Risco Extremo):** neossolo_arenoso, sequeiro_convencional, tardia_dezembro, severo_mais_14d → Quebra esperada > 92%.
- Teste 3 (Dilema Edáfico):** neossolo_arenoso, mas com irrigado_pivo e plantio ideal (Avalia se a irrigação compensa a fragilidade da areia).

- **Teste 4 (Solo Forte sob Clima Hostil):** latossolo_argiloso, porém com veranico severo e chuva deficitária (Avalia a resistência da argila).
- **Teste 5 (Teste de Laplace):** Perfil com um valor não registrado nos dados de treino para certificar que o script SQL não quebra nem gera divisão por zero.

6. Reflexão Crítica para a Apresentação Oral

Onde o Naive Bayes acerta: Apresenta altíssima velocidade computacional em SQL e ótima assertividade em cenários com extremos climáticos nítidos.

Onde o Naive Bayes falha no contexto de MT: A premissa de que as variáveis são estatisticamente independentes é falsa no campo. Na realidade do cerrado mato-grossense, um neossolo_arenoso multiplica exponencialmente o dano de um veranico_dias = severo_mais_14d, pois o solo não tem microporos para reter água residual. O Naive Bayes apenas soma os pesos isoladamente, subestimando o risco sinérgico entre solo e seca.